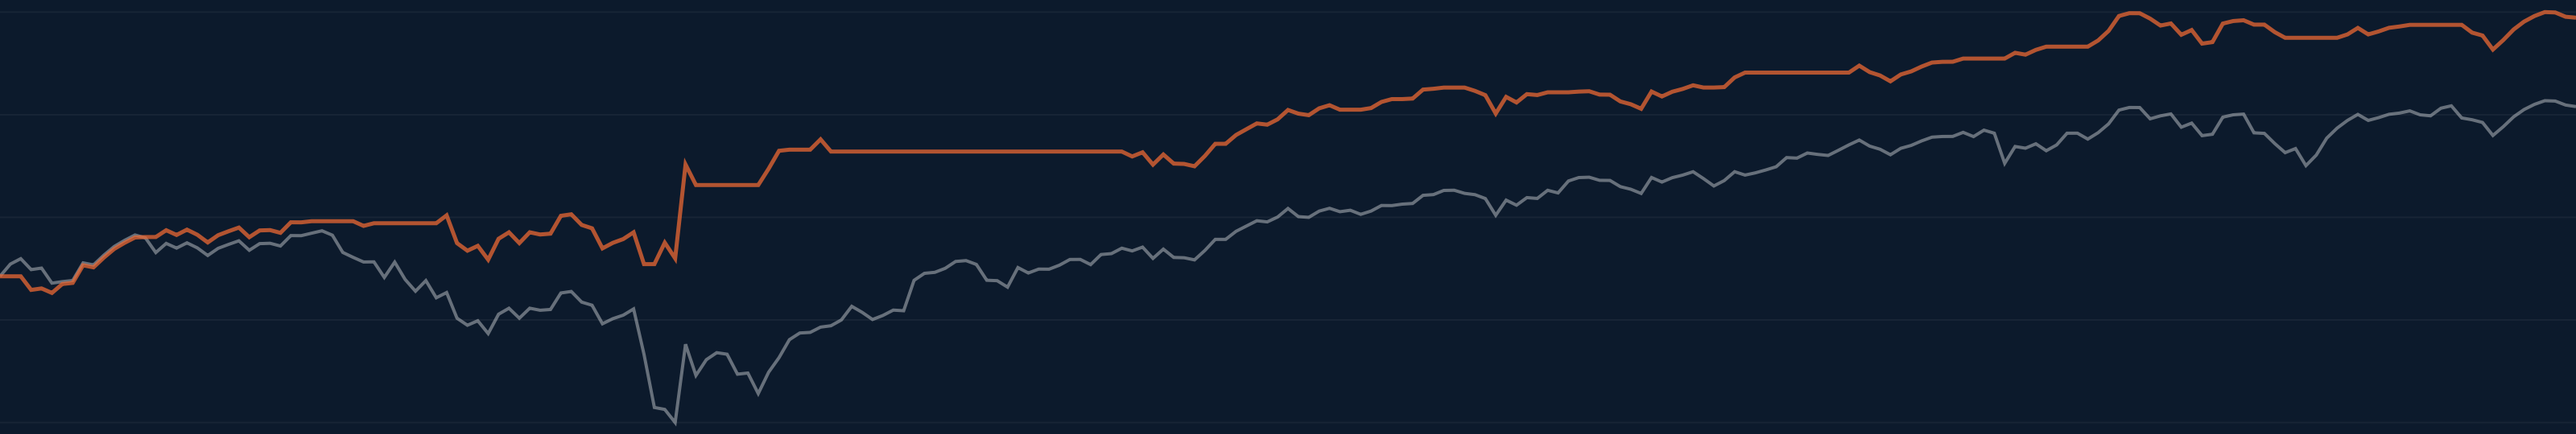
TRABAJO DE FIN DE MÁSTER

Universidad Internacional de Valencia

Sistema de apoyo a la decisión financiera basado en aprendizaje automático

para la predicción de tendencias bursátiles y evaluación mediante backtesting



ALUMNO
Lucas Niño Ruiz

DIRECTOR DEL TFM
Dr. Arturo Peralta Martín-Palomino

TITULACIÓN
Máster Universitario en Big Data y Ciencia de Datos

CONVOCATORIA
Primera convocatoria

FECHA DEFENSA
30 de octubre de 2026

Índice

01	**Introducción**	Motivación, pregunta del trabajo y métricas financieras
02	**Metodología**	Datos, variables, modelos y validación temporal
03	**Desarrollo**	Implementación y problemas de los datos
04	**Resultados**	Hipótesis H1 a H4 en 2025 y validación de 2016 a 2025
05	**Conclusiones**	Conclusiones, limitaciones y líneas futuras

Contexto y motivación

- Históricos de datos y modelos de aprendizaje automático muy accesibles
- Estrategias que prometen rentabilidad sin comprobaciones con el rigor pertinente
- Probando muchas configuraciones, alguna sale bien por puro azar (sobreajuste del backtest) (Bailey et al., 2014)

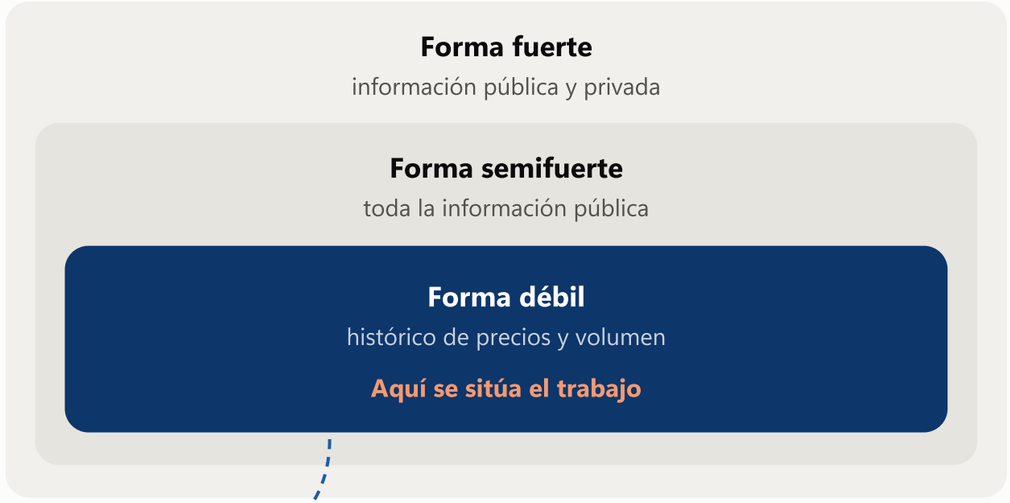
Cuestión a contestar

Usando solo precio y volumen, ¿puede un modelo ganar a una referencia que no usa información y a comprar y mantener?

Hipótesis y criterio de éxito declarados antes de ver resultados

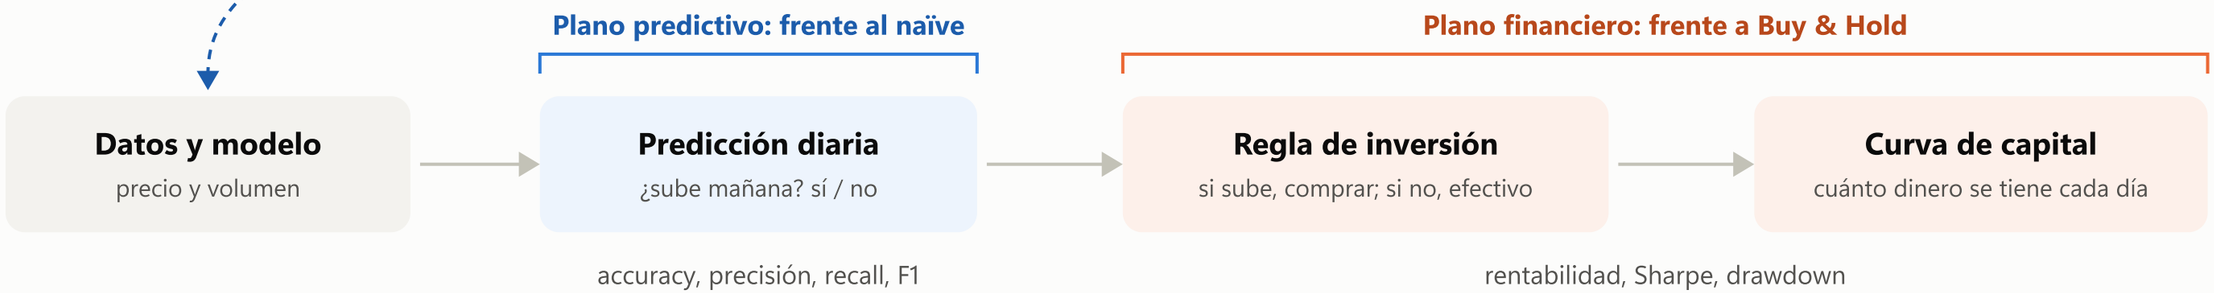
Bailey, D. H., Borwein, J. M., López de Prado, M. y Zhu, Q. J. (2014). Pseudo-mathematics and financial charlatanism: The effects of backtest overfitting on out-of-sample performance. *Notices of the American Mathematical Society, 61*(5), 458-471. https://doi.org/10.1090/noti1105

Planteamiento del problema



Hipótesis del Mercado Eficiente (Fama, 1970): en su forma débil, dice que el precio de hoy ya refleja toda la información de los precios pasados.

Tarea: "¿La próxima sesión cierra por encima de la de hoy?" → Sí / No → clasificación binaria

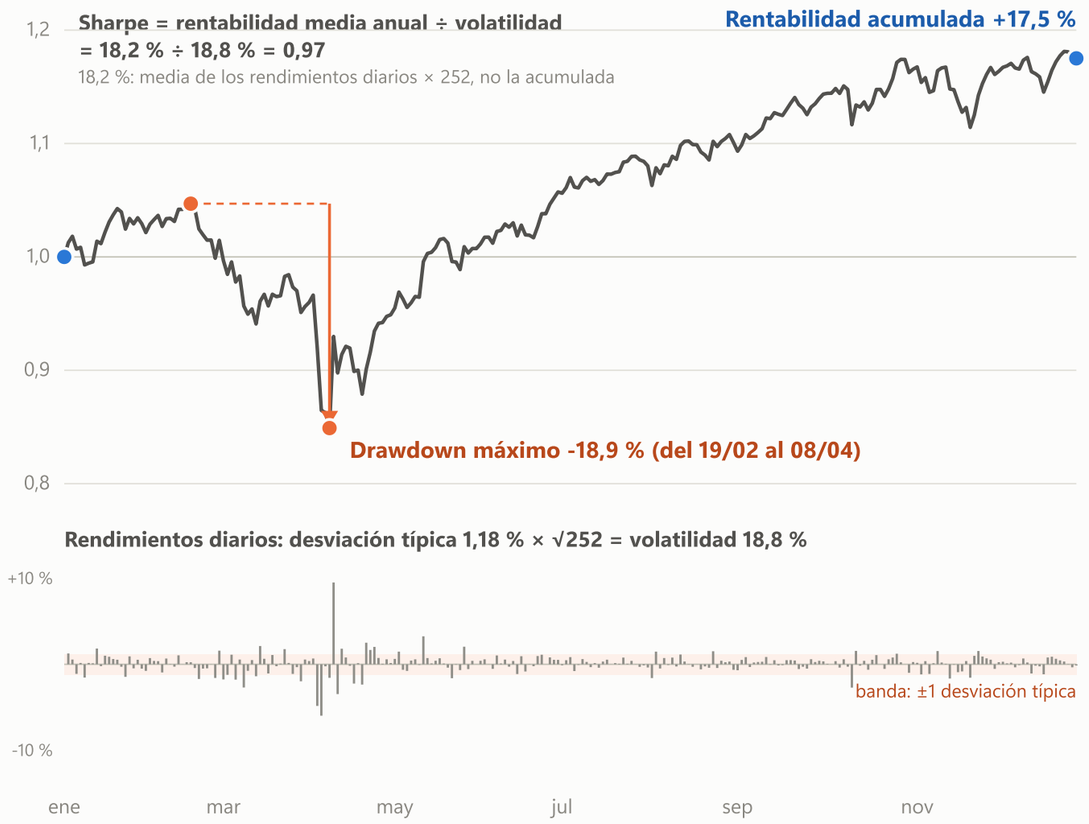


Los dos planos se evalúan por separado y no tienen por qué coincidir

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance, 25*(2), 383-417. https://doi.org/10.1111/j.1540-6261.1970.tb00518.x

Cómo se mide una estrategia

Buy & Hold sobre el S&P 500 en 2025 (capital inicial = 1)



Buy & Hold	Comprar el primer día y no tocar nada. Es la referencia pasiva.
Rentabilidad acumulada	Cuánto crece el capital en todo el periodo: **+17,5 %**.
Drawdown máximo	La mayor caída desde un máximo anterior: **-18,9 %**.
Volatilidad anualizada	Cuánto oscilan los rendimientos diarios: desviación típica diaria × √252: **18,8 %**. Es la medida de riesgo más habitual.
Ratio de Sharpe	Rentabilidad media anual entre volatilidad (con R_f = 0): ganancia por unidad de riesgo, **0,97**.
Larga / liquidez	Tener el activo comprado / tener el dinero en efectivo. No uso posiciones cortas (apostar a la baja).

Objetivos

Construir un sistema que prediga la dirección del precio y comprobar con backtesting si aporta algo frente a una estrategia pasiva.

OE1	Adquisición de datos	14 activos, cada uno con su calendario	**M1**
OE2	Construcción de variables	sin usar información futura	**M2**
OE3	Entrenamiento y comparación	6 familias con la misma validación	**M3**
OE4	Evaluación financiera	cada estrategia frente a Buy & Hold	**M4 y M5**
OE5	Cuantificación del riesgo	volatilidad, Sharpe y drawdown	**M4**

Hipótesis de trabajo

General: el aprendizaje automático puede ayudar como complemento, pero su ventaja real en dinero es limitada y poco sistemática.

H1	Los modelos aciertan más que el naïve	contraste binomial y Bonferroni
H2	Los modelos no lineales mejoran a la regresión logística	McNemar exacto, 42 comparaciones
H3	Acertar más no implica ganar más	rentabilidad y Sharpe frente a Buy & Hold
H4	La LSTM no compensa su mayor coste	mismas métricas y misma partición

Fijadas antes de ver ningún resultado. H4 está planteada en negativo.

Datos y muestra

Índices (cestas de acciones que resumen un mercado)

S&P 500, NASDAQ, IBEX 35 y DAX

ETF global (fondo que cotiza como una acción y replica un índice)

MSCI ACWI

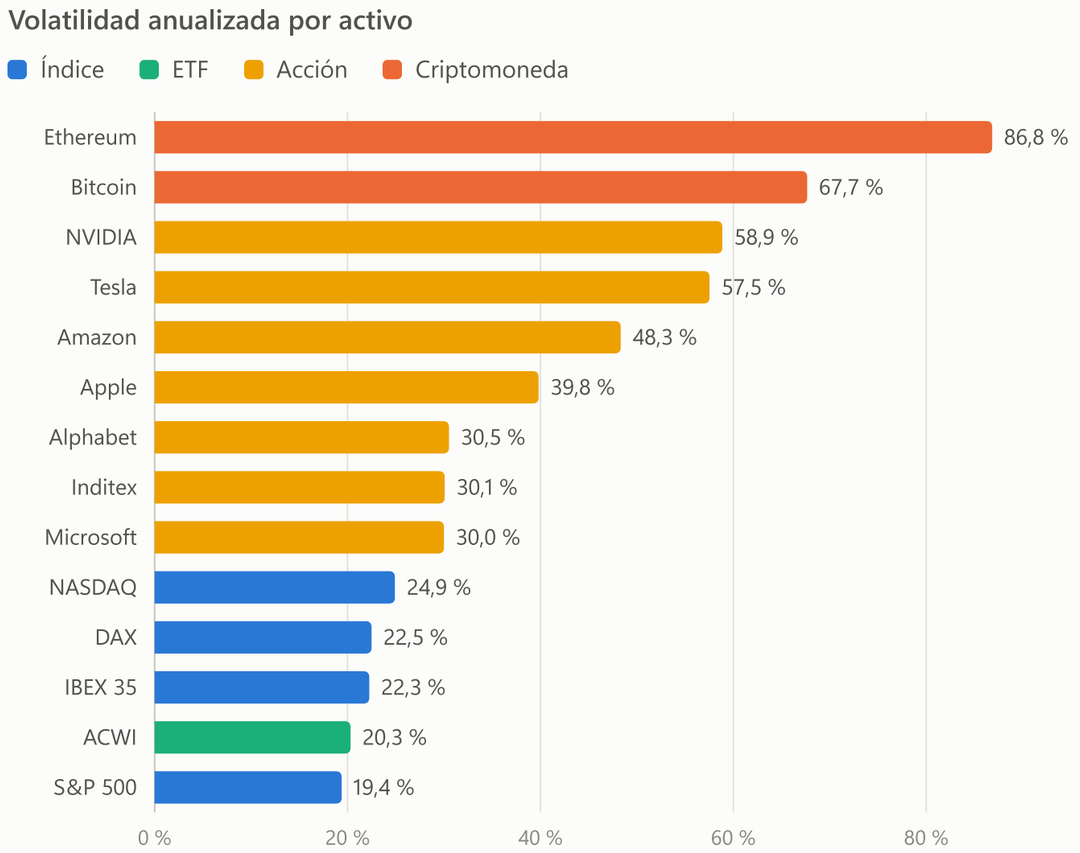
Acciones (cotizan unos 252 días al año)

Apple, Microsoft, NVIDIA, Alphabet, Amazon, Tesla e Inditex

Criptomonedas (cotizan 365 días al año)

Bitcoin y Ethereum

Datos diarios	apertura, máximo, mínimo, cierre y volumen (yfinance)
Precios	ajustados por dividendos y desdoblamientos
Periodo	2000-2025, o desde que existe el activo: 79.260 sesiones
Prueba 2025	entre 229 y 364 sesiones por activo
Huecos	se eliminan, nunca se rellenan



Variables predictoras y variable objetivo

Familia	Qué mide	Variables	N.º
Retornos	cuánto varió el precio	$\ln(P_t/P_{t-1})$	1
Medias móviles	la tendencia	20 y 50 sesiones y su cociente	3
Volatilidad	cuánto oscila	desviación típica, 20 sesiones	1
Volumen	cuánto se negocia	variación porcentual	1
RSI (14)	peso de las subidas frente a las bajadas	índice de 0 a 100	1
MACD (12, 26, 9)	cruce de dos medias exponenciales	línea, señal e histograma	3

Qué se predice

$$y_t = \begin{cases} 1 & \text{si } P_{t+1} > P_t \text{ (sube)} \\ 0 & \text{si no} \end{cases}$$

- Todo se calcula con datos hasta el cierre de cada día
- Horizonte definido antes de ver resultados
- Entre el 50,2 % y el 54,2 % de días de subida → clases casi equilibradas

Modelos comparados

Del más simple al más complejo. Misma partición y fechas de prueba.

Naïve

siempre la clase más frecuente del entrenamiento

`sin ajuste`

Regresión logística

la referencia lineal

`C ∈ {0,01; 0,1; 1; 10}`

Random forest

muchos árboles en paralelo

`200/400 árboles`
`prof. 5/10/∞, hoja 1/5`

XGBoost

árboles que corrigen al anterior

`200/400 árboles`
`prof. 3/5/7, tasa 0,05/0,1`

SVM

frontera con el mayor margen (núcleo RBF)

`C ∈ {0,1; 1; 10}`
`γ ∈ {escala; 0,01}`

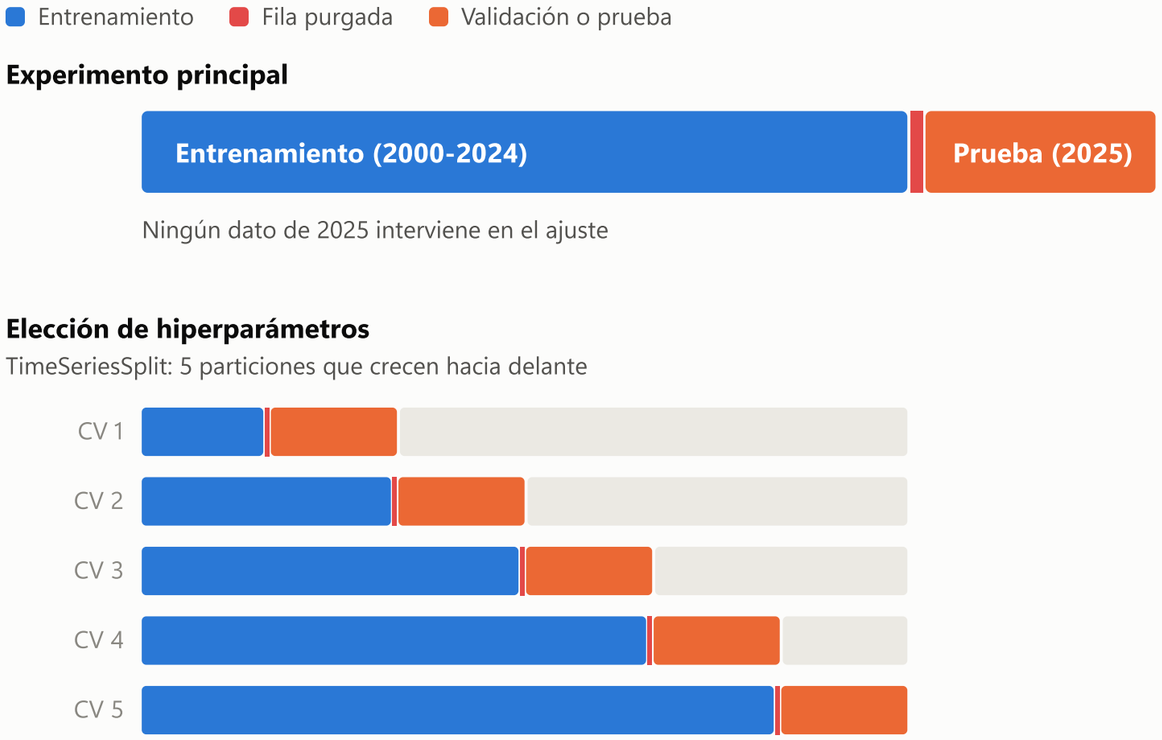
LSTM

red recurrente que lee 30 sesiones seguidas

`64 unidades, dropout 0,2`
`50 épocas, sin rejilla`

Complejidad creciente

Validación temporal



Purga: se quita la última fila del entrenamiento porque su etiqueta usa el precio del día siguiente, que pertenece al periodo de test.

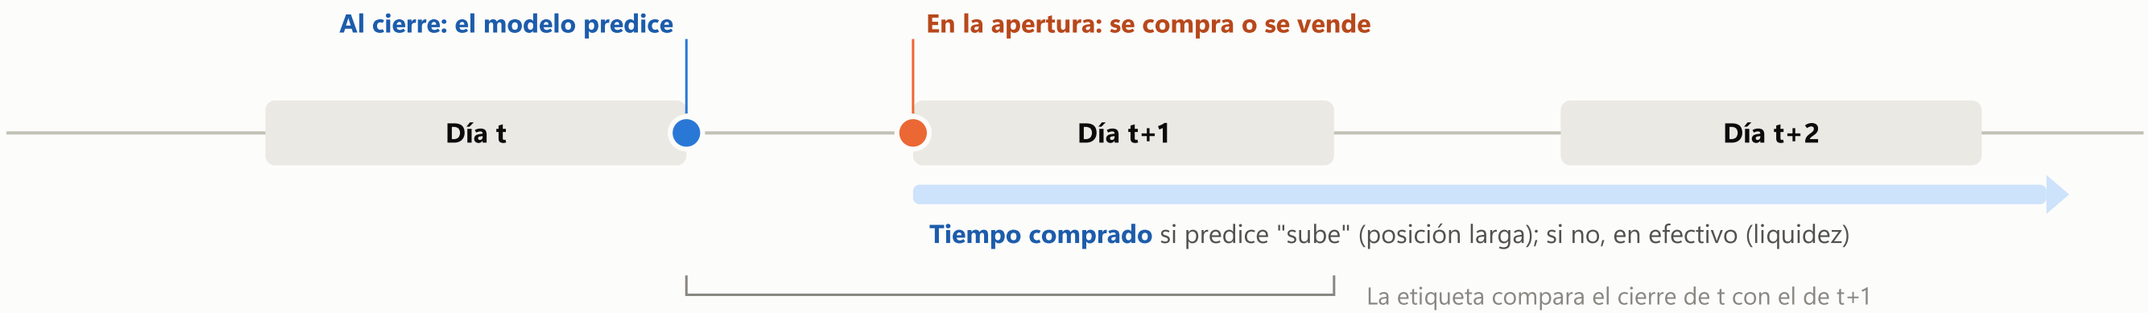
Criterio de selección: balanced accuracy sobre F1.

Modelo que siempre dice "sube"	p = 0,51	0,54	0,60
F1	0,675	0,701	0,750
Balanced accuracy	0,500	0,500	0,500

p: proporción de días de subida. Solo para elegir hiperparámetros; los resultados se dan en accuracy, precisión, recall y F1.

Backtesting y criterio de éxito

Backtesting es simular sobre el histórico qué habría pasado invirtiendo según las predicciones.



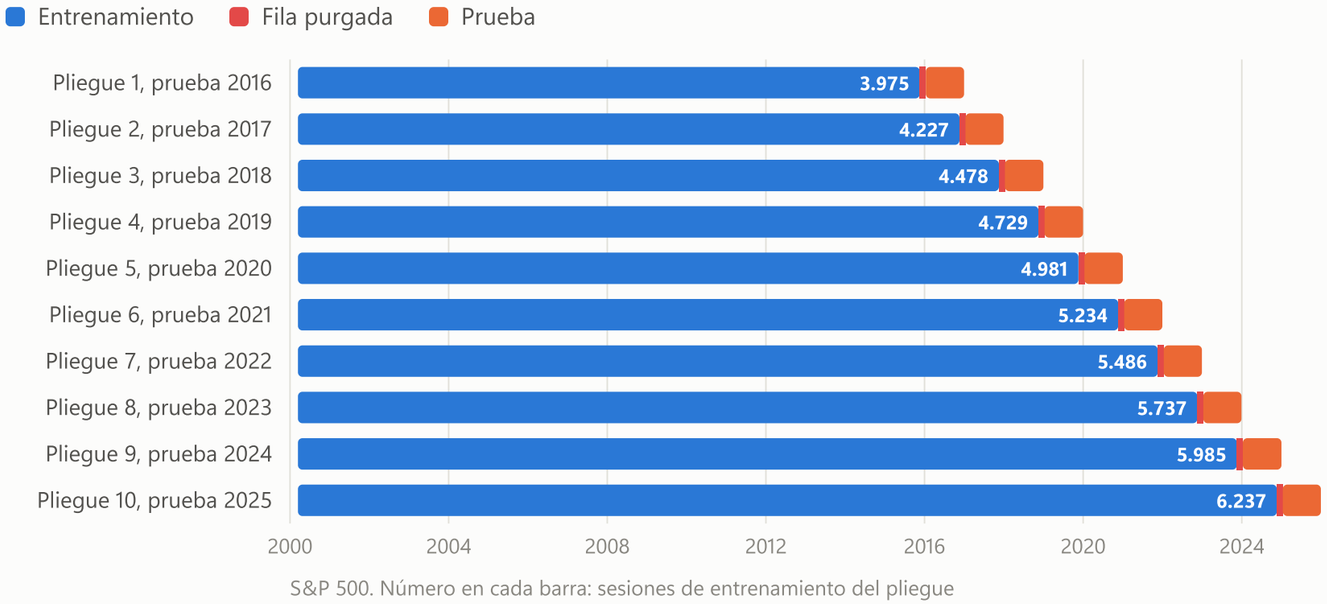
Antes de evaluar, se declara el criterio de éxito:

Aporta valor si gana a Buy & Hold en rentabilidad y en Sharpe a la vez

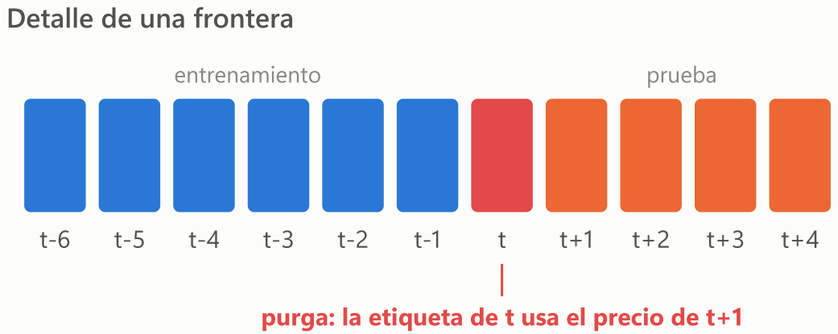
- Sin comisiones: cualquier resultado positivo es un máximo
- Nunca se apuesta a la baja (sin posiciones cortas)
- $R_f = 0$; con el 2 % o el 4 % no cambia ningún "aporta valor"

Validación walk-forward

Para ver si 2025 fue un año normal, se repite el experimento año a año entre 2016 y 2025.



S&P 500. Número en cada barra: sesiones de entrenamiento del pliegue



129 pliegues, uno por activo y año

774 evaluaciones (645 de ML)

5 años de historia mínima para entrenar

6 y 3 pliegues de Bitcoin y Ethereum

Arquitectura del pipeline



Cuestiones prácticas de los datos

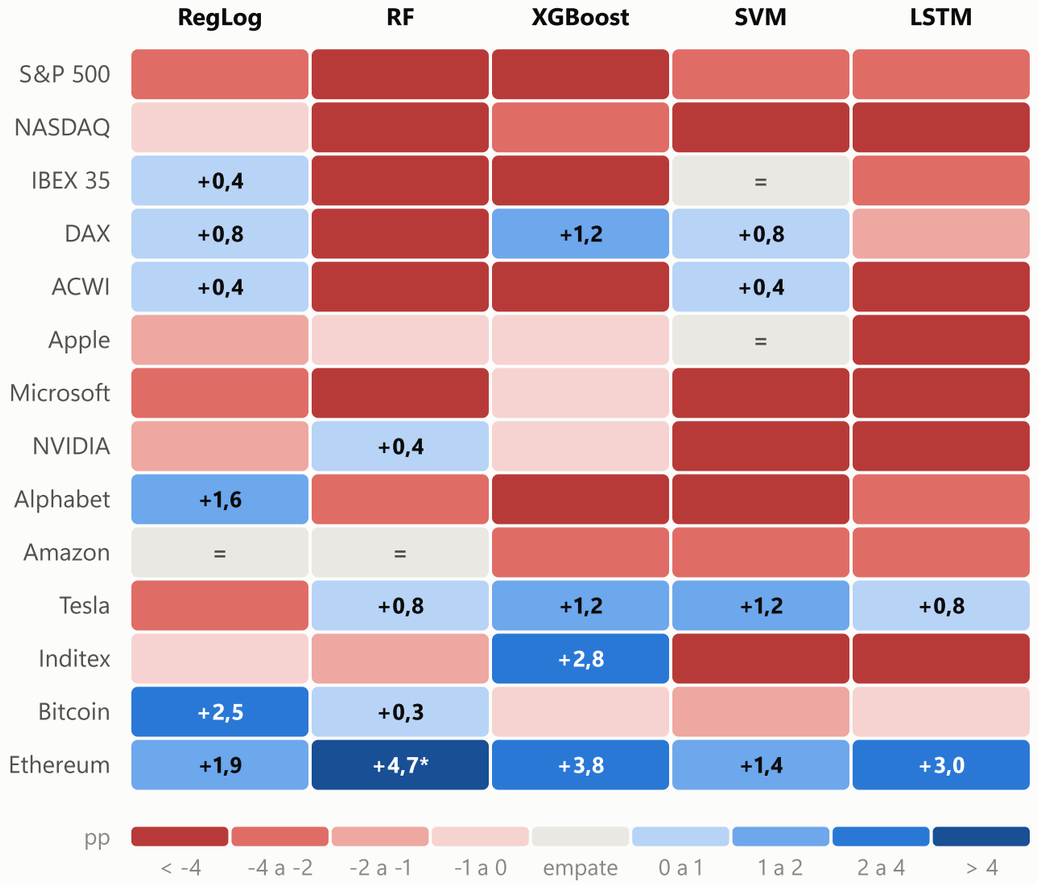
Durante el desarrollo aparecieron varios problemas con los datos y con la simulación. Estos problemas no siempre daban error en el código.

Problema	Causa	Solución
Inditex: 349 precios ajustados negativos	los retornos se calculaban igual, sin aviso	se eliminan en M1
IBEX 35: imputa volumen 0 cuando no hay dato	$(V_t - V_{t-1}) / V_{t-1}$: división entre cero → valores infinitos	el cero se trata como dato ausente
Índices con unidades enteras	no se compraba nada → rentabilidad nula	unidades fraccionarias
Calendarios distintos entre mercados	al alinearlos aparecen días inventados	un calendario por activo

También se desarrollaron pruebas automáticas para estas correcciones. Las cifras usadas son las de la última ejecución.

Capacidad predictiva frente al azar (H1)

Veinte de los setenta pares superan al naïve, pero ninguno resiste la corrección por comparaciones múltiples.



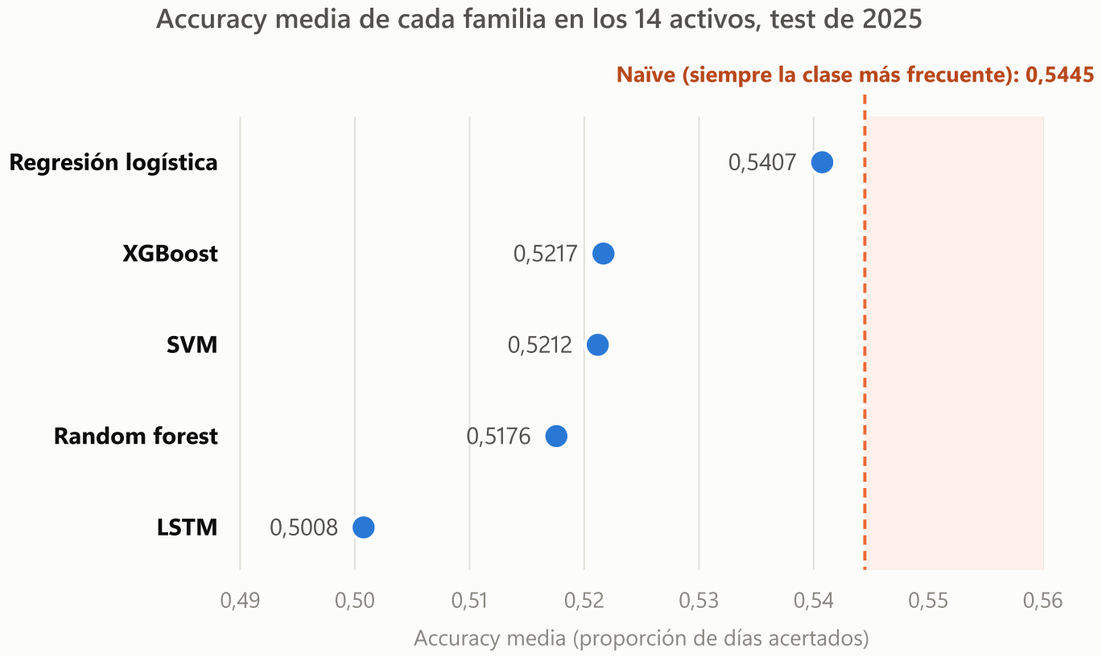
Test de 2025. Diferencia de accuracy respecto al naïve en puntos porcentuales.
* p < 0,05 sin corregir

20 de 70	pares superan al naïve (5 por una sola sesión)
1	con p < 0,05: RF en Ethereum (p = 0,0418)
0	tras Bonferroni (umbral 0,05/70)

H1 no recibe respaldo suficiente

Aportación de la complejidad del modelo (H2)

Los modelos no lineales no mejoran significativamente a la regresión logística.



42	comparaciones con McNemar: cada modelo no lineal frente a la regresión logística (RL), activo a activo
1	con p < 0,05, a favor de la RL: XGBoost en ACWI (p = 0,0184). La RL acierta sola 91 sesiones y XGBoost, 61
0	tras Bonferroni

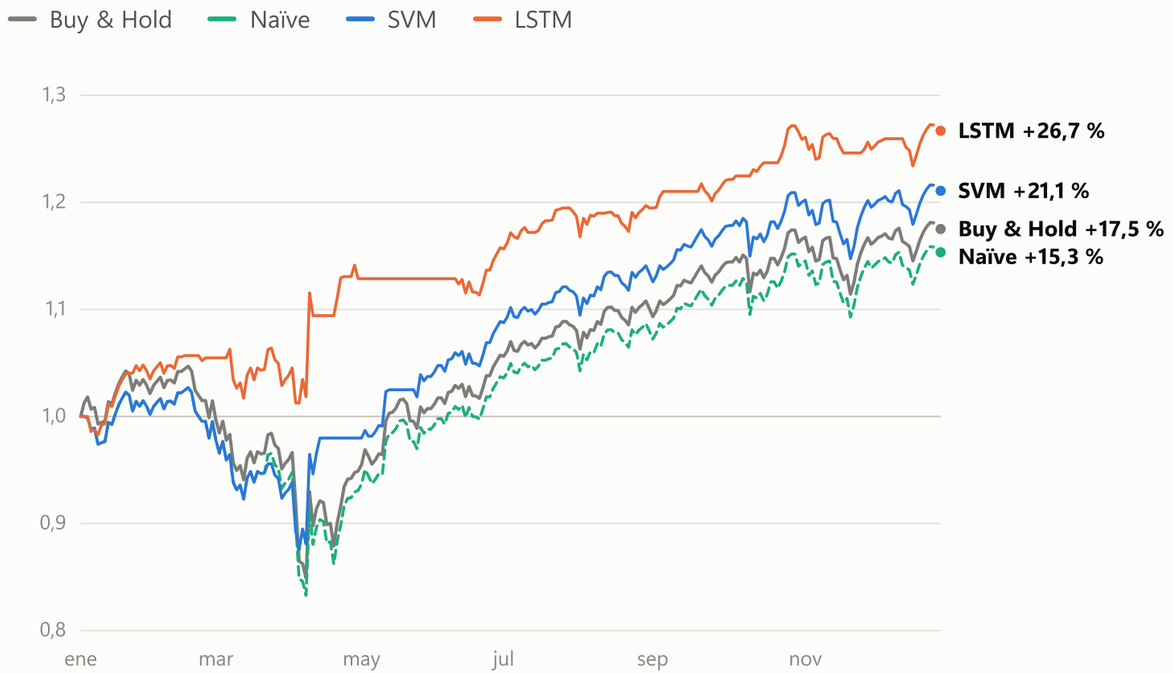
H2 no se confirma

Ejemplo: S&P 500 en 2025

Acierto y resultado financiero de cada modelo en el periodo de prueba.

Modelo	Accuracy	F1	Rent.	Sharpe	¿Valor?
Buy & Hold	-	-	+17,51 %	0,97	-
Naïve	**0,5783**	**0,7328**	+15,34 %	0,87	No
RegLog	0,5462	0,7018	+14,17 %	0,83	No
RF	0,5221	0,5854	+6,93 %	0,48	No
XGBoost	0,5141	0,5980	-0,14 %	0,08	No
SVM	0,5462	0,6938	+21,08 %	1,24	**Sí**
LSTM	0,5542	0,6078	+26,69 %	1,78	**Sí**

Rent.: rentabilidad acumulada
Valor: gana a Buy & Hold en rentabilidad y en Sharpe



Capital normalizado a 1 al inicio de 2025

Utilidad financiera frente a utilidad estadística (H3)

Cruce entre superar al naïve en accuracy y aportar valor frente a Buy & Hold (70 pares, test de 2025).

	Aporta valor	No aporta valor
Supera al naïve 20 pares 80 % con valor	**16** coinciden los dos planos	**4** aciertan más, pero no ganan
No lo supera 50 pares 28 % con valor	**14** ganan sin acertar más	**36** coinciden los dos planos

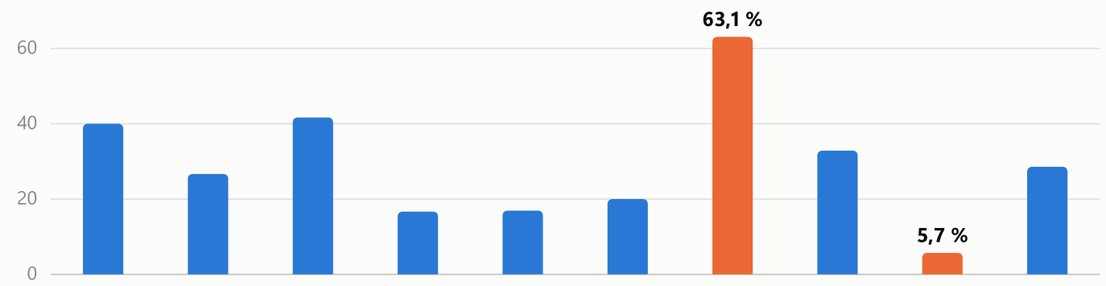
30 de 70	pares ganan a Buy & Hold en rentabilidad y Sharpe (sin costes)
68 de 70	tienen menos volatilidad que Buy & Hold; pasan parte del tiempo en efectivo

H3 recibe apoyo descriptivo

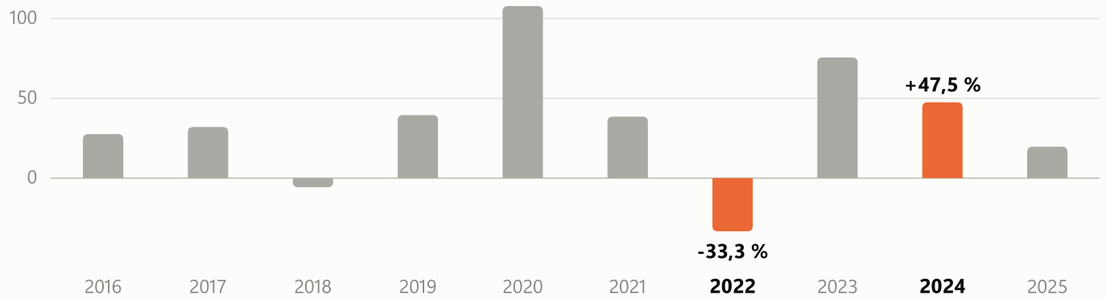
Walk-forward: plano predictivo

Con diez años los modelos aciertan de media menos que el naïve, y es muy dependiente del año.

Evaluaciones de ML que superan su referencia ingenua (%)



Retorno medio de Buy & Hold en el año (%)



0,5074	accuracy media en 645 evaluaciones (naïve: 0,5312)
29,0 %	superan su referencia ingenua (187 de 645)
2 de 33	con p < 0,05 resisten Bonferroni (Microsoft, 2018); por azar se esperarían unos 32

Test de signos: ¿gana más años de los que daría el azar?

2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
no	no	sí	sí	sí	no	sí	sí	sí	sí

El mejor par, SVM en el DAX, supera a su naïve en 7 de 10 años. Si cada año fuera cara o cruz (50 %), ganar 7 o más pasaría con probabilidad 0,17. Ninguno de los 70 pares baja de 0,05.

Walk-forward: plano financiero

Juntando los diez años, los pares que ganan a Buy & Hold bajan de 30 a 6 de 70.

Activos que superan a Buy & Hold en rentabilidad y en Sharpe (máx. 14)

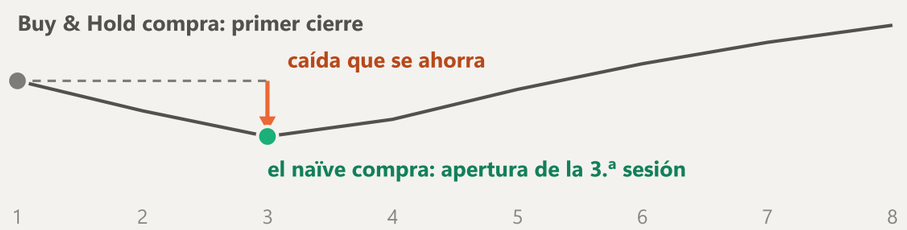
Familia	Test de 2025	2016-2025
Regresión logística	7	2
Random forest	6	2
XGBoost	7	0
SVM	6	1
LSTM	4	1
Total ML (de 70)	**30**	**6**
Naïve (sin información)	**1**	**7**

6 de 70 pares ganan a Buy & Hold (8,6 %; en 2025, 42,9 %)

7 de 14 activos en los que lo consigue el propio naïve, sin usar información

Por qué gana el naïve

esquema; sesiones del año



Buy & Hold se mide del primer cierre al último. El simulador compra en la apertura de la tercera sesión y vende en la apertura de la última: si el precio baja esos primeros días, el naïve se ahorra la caída sin predecir nada.

Coste del aprendizaje profundo (H4)

La LSTM es la familia que menos acierta y no gana más que las demás.

Familia	Accuracy media	Superan al naïve	Aportan valor
Regresión logística	0,5407	6 de 14	7 de 14
Random forest	0,5176	4 de 14	6 de 14
XGBoost	0,5217	4 de 14	7 de 14
SVM	0,5212	4 de 14	6 de 14
LSTM	**0,5008**	**2 de 14**	**4 de 14**

Test de 2025, 14 activos por familia.

19.265 parámetros

35 s de entrenamiento por activo, en CPU

H4 es compatible con lo observado

Para esta red y estos hiperparámetros

Resolución de las hipótesis

H1	**Acertar más que el naïve**	20 de 70 lo superan. Ninguno tras Bonferroni	Sin respaldo suficiente
H2	**Mejorar a la regresión logística**	1 de 42 con $p < 0,05$, y a favor de la lineal	No se confirma
H3	**Acertar más no implica ganar más**	4 aciertan más sin ganar y 14 ganan sin acertar más	Apoyo descriptivo
H4	**La LSTM no compensa**	tiene la accuracy media más baja y solo aporta valor en 4 de 14 activos	Compatible
H	**Hipótesis general**	ventaja en dinero pequeña y poco sistemática; no se demuestra que el ML ayude	Matizada

Conclusiones

1	Objetivos OE1 a OE5 cumplidos	el experimento se reproduce desde el repositorio
2	No hay ventaja predictiva generalizable	20/70 en 2025, ninguno tras Bonferroni; 29 % en 2016-2025
3	Acertar más no implica ganar más	14 pares aportan valor sin superar al naïve
4	La ventaja financiera no se mantiene en el tiempo	de 30/70 en 2025 a 6/70 en 2016-2025

Limitaciones y prospectiva

Limitaciones

- Sin costes de transacción: lo positivo es un máximo
- 14 activos y solo precio y volumen
- Sin estrategias de control con la misma exposición
- LSTM sin búsqueda de hiperparámetros

Prospectiva

- Validar con datos posteriores a 2025
- Añadir costes y controles de exposición
- Variables macroeconómicas, fundamentales y de noticias
- Walk-forward con ventana deslizante y otros mercados
- Predecir la volatilidad (GARCH frente a LSTM)

Gracias por su atención

Lucas Niño Ruiz, Máster Universitario en Big Data y Ciencia de Datos (VIU)

Código fuente: github.com/al375842/TFM-VIU

